

## LG BOOTCAMP 2026

---

# Oracle

On-Device AI 관상 및 사주 분석 서비스

A반 1팀

박현우 · 김승진 · 나혁주 · 송유진

# 목차

01. 주제 선정 배경

02. 서비스 개요 및 핵심 기능

03. 핵심 기술 및 구현 기술

04. 주요 구현 결과

05. 프로젝트 회고

# 01. 주제 선정 배경

# 01. 주제 선정 배경

WHY NOW - 왜 지금 사주·관상인가

- 1 미래 불확실성 속에서 **자기이해·진로·인간관계**에 대한 심리적 해답을 찾으려는 수요가 꾸준히 증가
- 2 MZ세대에게 사주 · 관상은 미신이 아니라 **자기탐색이자 놀이 콘텐츠**로 소비되는 추세
- 3 대학 축제 · 팝업스토어 · 행사 · 관광지 등 **2030 밀집 공간에서 체험형 서비스 수요**가 특히 큼

## 01. 주제 선정 배경

PROVEN - 'AI 사주' 사주아이의 폭발적 성공

50억

창업 수익

150억

누적 회원

500만

거래 건수

비개발자 1인 창업 · 광고비 0원·생성형 AI 기반 990원 사주로 폭발적 성장  
"왜 이런 운인지" 이유와 **개운법**까지 설명해 높은 만족도를 확보.



[https://fastcampus.co.kr/story\\_interview\\_sajuvibecoding](https://fastcampus.co.kr/story_interview_sajuvibecoding)

# 01. 주제 선정 배경

TREND – 저비용 · AI · 콘텐츠화라는 공통 공식



## 사주아이

990원 AI 사주, 모바일 최적화,  
결과를 SNS/공유로 확산시켜  
소셜 콘텐츠로 성장.



## 청월당 사주

사주 해석을 웹툰 형식으로 풀어내  
진입장벽을 낮춘 사례.  
어려운 명리를 친근하게 전달.



# 01. 주제 선정 배경

SO, ORACLE - 성공 공식은 잇되, 관상·온디바이스로 진화

## 기존 AI 사주 서비스

- 개인 정보가 서버로 전송, 민감정보(얼굴)는 다루지 않음
- 네트워크 상태에 영향을 받음
- 사주 해석 단일 모달
- 클라우드 기반 -> 서버.통신 비용



## Oracle의 차별점

- 모든 데이터 기기 내부에서 처리  
→ 프라이버시 확보
- 네트워크 지연 없이 응답
- 카메라 관상+사주 멀티모달 체험
- 100% 온디바이스(Edge AI) -> 클라우드 비용 0

## 02. 서비스 개요 및 핵심 기능

## 02. 서비스 개발 목표 및 핵심 기능

WHAT - ORACLE이 구현하고자 한 핵심 서비스

| 개발 목표     |                                   |
|-----------|-----------------------------------|
| 사주 분석     | 만세력 DB 기반 사주 분석 및 LLM 해석 제공       |
| 관상 분석     | 카메라 기반 얼굴 인식 및 랜드마크 분석 후 관상 정보 제공 |
| 궁합 분석     | 두 사람의 정보를 통합한 관계별 궁합 리포트 생성       |
| 온-디바이스 AI | 라즈베리파이 로컬 LLM 기반 AI 서비스 구현        |

| 분류       | 핵심 기능                     |
|----------|---------------------------|
| 서비스 목표   | 제품, 입력, 분석 리포트            |
| 분석 파이프라인 | 얼굴 캡처, 관상 분석, 사주/만세력, LLM |
| 운영 구조    | 실행 및 설정, 분산 시스템, 비기능      |
| 개인정보     | 데이터, 보안 및 개인정보            |
| 검증       | 테스트, 완료                   |

## 02. 서비스 개발 목표 및 핵심 기능

### WHAT – ORACLE 서비스 화면 구성

ORACLE 운

관상 & 사주 · 운명 해설

안녕하세요!  
오늘도 **운명**을  
함께 찾아볼까요?

오라와 함께 나의 운명과 인연을  
쉽고 재미있게 알아보세요!



#### 나의 운세 보기

사주 · 관상 · 운세를  
종합적으로 분석해드려요!

시작하기 →



#### 우리 궁합 보기

두 사람의 인연과 궁합을  
AI가 정밀하게 분석해드려요!

시작하기 →



#### 얼굴 분석

사진 한 장으로  
관상을 분석해요



#### 사주 분석

생년월일서들 기반으로  
사주를 분석해요



#### 100% 온디바이스

모든 분석이 기기 내에서  
이루어져 안전해요



#### 프라이버시 보호

당신의 데이터는 외부로  
전송되지 않아요

입력 다시 하기

처음으로

리포트 다운로드

ORACLE

사주 리포트

甲

갑목 · 陽木

당신은 마치 봄날의 새싹처럼 뚜렷한 성장 방향성과 강한 추진력을 가진 분이예요! 끈기 뿐이 나가는 기운 덕분에 새로운 일에 도전하는 것을 두려워하지 않는 에너지가 넘치거든요. 다만, 너무 앞만 보고 달려다 보면 잠시 멈춰서 숨을 고를 시간이 필요할 수 있습니다. 꾸준히 나아가는 힘이 정말 대단하지만, 그 여정 속에서 자신만의 단단한 기준점을 세우는 것이 아주 중요할 거예요!

송유진 님

♂ 1997. 04. 12 · 오시(午時) · 여성 · 양력

火

목

2

火

화

2

土

토

2

金

금

2

水

수

0

✿ 오행의 균형

사주에 나타난 오행의 분포를 통해 균형을 살펴봐요.

나로 기운이 허약하게 자란다. 원이 카타 펄이어서 시작은 저만 커다랗고 원하게 임시진마 후트를 보드려게 가파중 물인

운!

다예요!

서 한 번 목표를 정하면 추진력 있게 밀어붙이는 힘이 엄청나답 서서 숨을 고르는 시간이 꼭 필요한 시기가 찾아올 거예요. 이 계서 기준을 세우는 심세함이 더해지면 완벽한 결실을 맺을 수

밀!

하고 목표가 뚜렷했고, 묵묵히 자신의 길을 개척해 나가는 모습 멈춰서 숨을 고를 시간이 필요해요. 이 에너지를 잘 조절하면 주

재물운과 작성

통장에 돈이 꽃힐 구체적인 비밀 루트를 알려드릴게요!

당신의 재물은 활동적인 아이디어와 전문적인 기술을 활용한 분야에서 예상치 못한 형태로 터질 운이랍니다!

앞으로의 재물 흐름은 좋은 기운이 단단하게 받쳐주는 안정적인 기반 위에서 빛을 발할 거예요. 특히 사람들과의 교류를 통해 새로운 아이디어를 구체화하는 프로젝트나, 전문 지식을 활용한 컨설팅 분야에서 예상 밖의 수입이 생길 가능성이 높아요. 이 시기에는 문서나 계약서와 관련된 일이 재정적 보상으로 연결되는 흐름이 강하니, 서류 작업을 꼼꼼히 챙기시는 게 중요해요. 투자보다는 본인의 역량을 발휘하는 일에 집중할 때 가장 큰 경제적 이득을 보게 될 거예요.

연애운과 인간관계

새로운 설렘의 씨앗, 운명의 인연은 어디에서 피어날까요?

숨겨진 매력에 빛을 발하며, 예상치 못한 장소에서 반박하는 인연을 만날 운이예요!

가을의 큰 호수 같은 기운이 짙어지는 시기에, 당신의 진중한 매력이 주변 사람들의 시선을 사로잡을 거예요. 특히 문화생활이나 조용한 학습 공간 같은 곳에서, 지혜롭고 생각이 깊은 매력의 사람을 만나게 될 가능성이 높아요. 이 만남은 우연처럼 보이지만, 사실은 당신의 내면적 성숙함이 이끌어낸 필연적인 인연이랍니다. 적극적으로 대화의 물꼬를 트는 용기가 필요하며, 가볍게 시작된 관계가 깊은 유대감으로 발전할 거예요.

올해의 운세

뜨거운 봄날의 기운이 당신의 성장속 폭발시킨 거예요!

## 03. 핵심 기술 및 구현 기술

### 03. 핵심 기술 및 구현 기술

#### DESIGN - 요구사항 설계

| 분류          | 핵심 기능                     |
|-------------|---------------------------|
| 서비스 목표      | 제품, 입력, 분석 레포트            |
| 분석<br>파이프라인 | 얼굴 캡처, 관상 분석, 사주/만세력, LLM |
| 운영 구조       | 실행 및 설정, 분산 시스템, 비기능      |
| 개인정보        | 데이터, 보안 및 개인정보            |
| 검증          | 테스트, 완료                   |

| ID       | 요구사항                                       | 인수기준                                                       |
|----------|--------------------------------------------|------------------------------------------------------------|
| LLM-004  | Reasoning 모드는 명시적으로 켜 때만 사용한다.             | --reasoning이 필요하다.                                         |
| LLM-005  | Prompt cache는 환경변수로 제어한다.                  | Id_slot이 prompt template 적용                                |
| DIST-002 | 사주 해설을 카테고리 단위 작업으로 나눌 수 있다.               | metadata 작업과 block 작업을 별도 생성한다.                            |
| DIST-003 | slave 상태를 조회해 idle/score 기반으로 작업을 배정한다.    | /api/distributed/status가 status, tps, compute_score를 반환한다. |
| REP-001  | 개인 리포트는 핵심 요약, 관상, 사주, 통합 요약을 포함한다.        | essence, face_blocks, saju_blocks, synthesis 영역이 렌더링된다.    |
| DATA-003 | data/physiognomy_rules.sqlite는 랜드마크 를 DB다. | 관상 룰 매칭에만 사용하고 개인정보를 담지 않는다.                               |
| SEC-002  | 로컬 처리 원칙을 사용자에게 알린다.                       | UI와 문서에서 온디바이스 처리 흐름을 설명한다.                                |
| NFR-002  | 카메라 미리보기 시작                                | 5초 이내                                                      |
| NFR-003  | 얼굴 조건 충족 후 캡처                              | 기본 2초 안정 후                                                 |
| TEST-001 | 사주 런타임 계산을 테스트한다.                          | 기준 샘플의 년월일시주가 일치한다.                                        |

## 03. 핵심 기술 및 구현 기술

### TECH - 사주풀이 성능

#### AI를 이용한 사주 / 관상 분석

- 개인 정보를 그대로 로컬 LLM input으로 넣으면 **hallucination이 발생**할 여지가 많이 존재.
  - 만세력을 직접 계산하는 로직을 사용해 최대한 정확한 정보 전달
  - Json 스키마에 맞게 **출력 제한해서 파싱**하는 구조로 안정성 확보해 무효 응답을 최소화
- 만세력 데이터를 세부적으로 해석하는 과정에서 정해진 데이터 접근만으로는 **자연스럽고 설득력 있는 사주 해석 불가능**
  - 1T이상 모델과 비슷한 사주풀이 결과를 보인 **Gemma-4-E2B 모델을 활용**하여 보다 자연스러운 사주·관상 분석과 해설을 제공

#### 사용자 친화적 UI 제공

- 사주풀이에는 일반인이 **직관적으로 이해하기 어려운 정보와 해석 요소**가 다수 포함됨
  - 이해하기 쉽고, 가독성 좋은 문장으로 풀이를 하도록 프롬프트 구성
  - **간결하고 직관적인 UI**를 통해 사용자가 사주·관상 해설을 쉽게 확인할 수 있도록 구성
  - 사주 해석에 필요한 주요 데이터를 **시각적으로 강조**하여 이해도를 향상

## 03. 핵심 기술 및 구현 기술

### TECH - 속도 최적화

#### llama.cpp 기반 로컬 추론 프레임워크


경량화 양자화 모델(GGUF) 모델 사용, 라즈베리파이 제한된 자원을 고려해 양자화 / 컨텍스트 캐싱 / MTP 등 여러 기법 적용

#### 캐시 최적화 프롬프팅

고정적으로 prefix 프롬프트는 Key-Value를 미리 만들어 사용할 수 있도록 KV 캐싱 모델 수정

#### 분산 최적화

멀티 디바이스 설치 시, 적응형 스케줄러를 직접 구현한 분산 시스템



## 04. 구현 결과

## 04. 구현 결과

RESULT - 사주 풀이 성능 결과

### GPT 5.5 Pro

#### 성향 및 심리패턴

기본적으로 신중하고 관찰력이 좋아 사람이나 상황의 흐름을 빠르게 파악하는 편입니다.

#### 적성

적성은 분석, 기획, 기술, 데이터, 연구, 시스템 설계처럼 구조를 이해하고 개선하는 일과 잘 맞습니다.

#### 총평

남들보다 속도가 느리다고 느껴질 수 있지만, 시간이 지날수록 경험과 신뢰가 자산이 되는 타입입니다.

### Ours

#### 성향 및 심리패턴

당신은 남들이 쉽게 엿볼 수 없는 깊은 감각으로 세상을 관찰하고, 차분하게 상황을 분석하는 능력이 정말 대단해요!

#### 적성

복잡한 데이터 속에서 구조를 이해하고 숨겨진 가치 있는 기회를 발견하는 데 탁월한 능력을 발휘할 수 있어요.

#### 총평

이처럼 섬세한 관찰을 멈추지 않고, 중요한 순간에 이처럼 멈춰 서서 생각하는 자세가 당신의 운명을 더욱 풍요롭게 만들 거예요!

## 04. 구현 결과

### RESULT - 속도 성능 결과

Gemma4-E2B 2bit 모델 기준 (20회 평균)

| 분류    | 측정 조건                                      |
|-------|--------------------------------------------|
| 입력 토큰 | 1,583 tokens<br>동일 prompt body 기준          |
| 출력 토큰 | 1,510 tokens<br>동일 max/new token 기준        |
| 비교 방식 | Vanilla / Prompt Cache / Distributed Split |
| 실행 기준 | 동일 모델·동일 질문·동일 리포트 구조                      |
| 해석 기준 | 사용자가 체감하는 전체 응답 시간<br>(wall-clock latency) |

#### 핵심 메시지

Prompt cache는 반복 prefix 처리 시간을 줄이고,  
분산 실행은 카테고리별 생성을 병렬화해 전체 대기 시간을 줄인다.

| 구분                | Input | Output | 처리 방식                      | 추론 시간  | 개선   |
|-------------------|-------|--------|----------------------------|--------|------|
| Vanilla           | 1,583 | 1,512  | 전체 prompt를 처리한다.           | 7분 02초 | 1.0x |
| Prompt Cache      | 1,583 | 1,510  | 공통 prefix/KV cache를 재사용한다. | 4분 30초 | 1.6x |
| Distributed Split | 1,583 | 1,511  | 각 block을 병렬 생성 후 병합한다.     | 3분 03초 | 2.3x |

Vanilla  
7분 02초  
기준값

Prompt Cache  
4분 30초  
약 36% 단축

Distributed Split  
3분 03초  
약 57% 단축

## 05. 프로젝트 회고

## 05. 프로젝트 회고

### REVIEW - 어려웠던 점과 대응 방법

제한된 보드 환경에서 LLM을 서비스 수준으로 동작시키기 위해, 성능·품질·운영 안정성의 균형을 맞추는 과정이 핵심 과제였습니다.

| 과제       | 문제 상황                                                                       | 대응 방향                                            |
|----------|-----------------------------------------------------------------------------|--------------------------------------------------|
| HW 자원 제약 | 메모리·CPU 성능이 제한되어 모델 크기와 응답 시간이 민감했다.                                        | 경량 모델, 토큰 제한, 캐싱 적용으로 처리 부담 완화                   |
| 속도 vs 품질 | 응답을 빠르게 만들수록 결과 문장 품질이나 상세도가 흔들릴 수 있었다.                                     | 프롬프트 정제와 JSON 형식의 스키마로 리포트 구조를 고정하고 input 토큰 최적화 |
| 분산 작업 관리 | Worker별 상태가 다르고 실패/지연이 발생할 수 있었다.                                           | 중앙 Job Queue, 상태 조회, retry 기준을 직접 구현             |
| 결과 일관성   | 카테고리별 생성 결과를 최종 리포트로 자연스럽게 합치는 과정이 필요했다. block 단위 생성 후 순서 기반 재조립 및 누락 처리 설계 |                                                  |


**가장 큰 난점** “작동하는 데모”를 넘어 사용자가 체감할 수 있는 응답 속도와 안정성을 확보하는 것



## 05. 프로젝트 회고

### REVIEW – Agent 기반 개발의 한계점

요구사항을 명확히 설계하고 하네스 엔지니어링으로 multi-agent를 프로젝트에 맞춰 설계하고 수행했지만, 프로젝트 규모가 커질수록 TDD만으로는 품질을 완전히 보장하기 어렵다는 점을 확인했습니다.



### Agent 개발 품질 확보 Flow



| 구분       | 핵심 회고                                    | 개선 포인트                             |
|----------|------------------------------------------|------------------------------------|
| 요구사항     | 명확히 설계해도 규모가 커지면 암묵적 가정과 누락이 남을 수 있음     | 입력·출력·예외·완료 기준까지 상세하게 지시           |
| 테스트      | Test case는 회귀 방지에 효과적이지만 전체 품질을 보장하지는 못함 | 핵심 시나리오와 엣지 케이스, 수동 리뷰를 병행         |
| Agent 활용 | Hallucination은 완전히 제거보다 지속적으로 줄이는 관리 대상  | 유저와 paraphrase를 반복하며 input 정확도를 높임 |

**THANK YOU**  
**QUESTIONS & ANSWERS**